

## Policy-Based Approach:

### Policy Gradient:

$$\text{Tip1: } \text{policy} = \text{Actor} = \text{Action}(\text{observation}) \\ = \pi_{\theta}(s)$$


How to learn a actor? 3 steps.

- Step 1: Define a set of functions:

Step 2: 求这些函数的好坏


Step 3: 得到最好的那个函数

Step 1: 定义很多的函数



$\theta$  是 NN 的参数

对于 Action 离散情形, Actor 的 Output 是一个关于动作的分布:



P.1

Q: 对于 Action 连续的情形, Actor 的 Output 是什么呢?

Step 2: 确定函数的好坏

用  $\pi_{\theta}$  会和 ENV 做互动:

$$\tau^1: \{s_1, a_1, r_1, s_2, a_2, r_2, \dots, s_T, a_T, r_T\}, \text{ Total Reward: } R_{\theta}(\tau) = \sum_{t=1}^T r_t$$

但  $R_{\theta}$  是个随机变量, 不足以用来衡量 Actor/policy 的好坏. 于是我们用  
一个统计平均值来衡量 Actor 的好坏, 以此降低随机性. 于是让  $\pi_{\theta}$   
去玩  $N$  次游戏:

$$\tau^1: \{s_1, a_1, r_1, s_2, a_2, r_2, \dots, s_T, a_T, r_T\}, \text{ Total Reward: } R_{\theta}(\tau) = \sum_{t=1}^T r_t$$

$$\tau^2: \{s_1, a_1, r_1, s_2, a_2, r_2, \dots, s_T, a_T, r_T\}, \text{ Total Reward: } R_{\theta}(\tau) = \sum_{t=1}^T r_t$$

⋮

$$\tau^N: \{s_1, a_1, r_1, s_2, a_2, r_2, \dots, s_T, a_T, r_T\}, \text{ Total Reward: } R_{\theta}(\tau) = \sum_{t=1}^T r_t$$

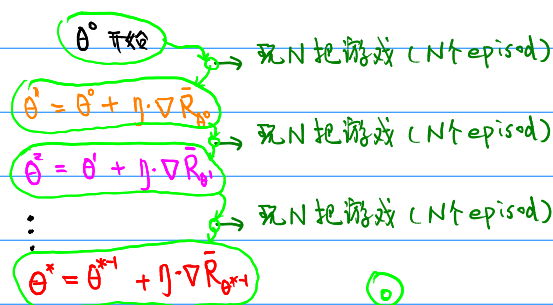
$$\frac{1}{N} \sum_{n=1}^N R_{\theta}(\tau^n) \approx \bar{R}_{\theta} = \sum_{\tau} R_{\theta}(\tau) P(\tau|\theta)$$

P.2

Step 3. 得到最优的那个函数:

$$\text{目标: } \theta^* = \arg \max_{\theta} \bar{R}_{\theta} = \arg \max_{\theta} \sum_{\tau} R_{\theta}(\tau) P(\tau|\theta)$$

怎么做: Gradient Ascent:



其中  $\nabla \bar{R}_{\theta}$  怎么算?

$$\bar{R}_{\theta} = \sum_{\tau} R(\tau) \cdot P(\tau|\theta)$$

$$\nabla \bar{R}_{\theta} = \sum_{\tau} R(\tau) \nabla P(\tau|\theta)$$

$$= \sum_{\tau} R(\tau) \cdot P(\tau|\theta) \cdot \frac{\nabla P(\tau|\theta)}{P(\tau|\theta)}$$

$$= \sum_{\tau} R(\tau) P(\tau|\theta) \nabla \log P(\tau|\theta)$$

$$= E_{\tau \sim p(\tau|\theta)} [R(\tau) \nabla \log P(\tau|\theta)]$$

$$\approx \frac{1}{N} \sum_{n=1}^N [R(\tau^n) \nabla \log P(\tau^n|\theta)]$$

玩 N 个 episodes

Q:  $\bar{R}_{\theta} \approx \frac{1}{N} \sum_{n=1}^N R_{\theta}(\tau^n)$ , 不能对  $\theta$  求偏导吗?

不知道应该怎么求?

知道  $\tau$ , 而不是  $\tau^n$  是因为这里是理论分析, 要对所有的 Trajectory  $\tau$  都要求和。

Q:  $R(\tau)$  和  $\theta$  无关? 怎么理解。

当  $\tau$  给定,  $R(\tau)$  由环境决定, 与  $\theta$  无关

Q:  $\nabla P(\tau|\theta)$  不能直接算吗?

不知道怎么算。

Q: 为什么要强行化成  $\log$  的形式?

方便后面去掉环境的那一项。

$\nabla \log P(\tau^n|\theta)$  怎么算?

$\tau: \{s_1, a_1, r_1, s_2, a_2, r_2, \dots, s_T, a_T, r_T\}$

$$P(\tau|\theta) = \overset{\text{Actor}}{p(s_1)} \cdot \overset{\text{ENV}}{p(a_1|s_1, \theta)} \cdot \overset{\text{Actor}}{p(r_1, s_2|s_1, a_1)} \cdot \overset{\text{ENV}}{p(a_2|s_2, \theta)} \cdot \overset{\text{Actor}}{p(r_2, s_3|s_2, a_2)} \dots \overset{\text{Actor}}{p(a_T|s_T, \theta)} \cdot \overset{\text{ENV}}{p(r_T, s_{T+1}|s_T, a_T)}$$

$$= p(s_1) \prod_{t=1}^T p(a_t|s_t, \theta) \cdot p(r_t, s_{t+1}|s_t, a_t)$$

同样的意思:

$$P(\tau^n | \theta) = P_\theta(\tau^n)$$

$$\log P(\tau^n | \theta) = \log p(s_1) + \sum_{t=1}^T \log p(a_t | s_t, \theta) + \sum_{t=1}^T \log p(r_t, s_{t+1} | s_t, a_t)$$

进而求梯度:

$$\begin{aligned} \nabla \log P(\tau^n | \theta) &= \nabla \left( \cancel{\log p(s_1)} + \sum_{t=1}^T \log p(a_t | s_t, \theta) + \sum_{t=1}^T \cancel{\log p(r_t, s_{t+1} | s_t, a_t)} \right) \\ &= \sum_{t=1}^T \nabla \log p(a_t | s_t, \theta) \end{aligned} \quad (2)$$

去掉环境的因素  
简化好多

将 (2) 代入 (1) 可以得到:

$$\nabla \bar{R}_\theta \approx \frac{1}{N} \sum_{n=1}^N [R(\tau^n) \nabla \log P(\tau^n | \theta)] = \frac{1}{N} \sum_{n=1}^N [R(\tau^n) \sum_{t=1}^T \nabla \log p(a_t | s_t, \theta)]$$

$$= \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T R(\tau^n) \nabla \log p(a_t | s_t, \theta)$$

统计得到      通过NN得到

$$\approx \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T [R_\theta(\tau^n) - b] \nabla \log p(a_t | s_t, \theta)$$

baseline

(3)

Q: 添加 Baseline 是为了解

使得  $[R_\theta(\tau^n) - b]$  有正

有负, 为什么要这样设计?

不可以吗?

$b$  是多少需要设计,  $R_\theta(\tau^n) - b$ , 给它一个新的名字

Advantage Function:

$$A^\theta(s_t, a_t) = R_\theta(\tau^n) - b$$

代表的意思是: 在  $s_t$  下采取  $a_t$  相比其他动作有多好。

$$= \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T A^\theta(s_t, a_t) \nabla \log p(a_t | s_t, \theta)$$

$$\nabla \bar{R}_\theta \approx \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T [R(\tau^n) - b] \nabla \log p(a_t | s_t, \theta)$$

$$= \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T \left[ \sum_{t'=t}^T \gamma^{t'-t} r_{t'}^n - b \right] \nabla \log p(a_t | s_t, \theta)$$

Why?


	Before			After		
	t=1	t=2	t=3	t=1	t=2	t=3
$\gamma=1, b=0$	$(s_1, a_1, +5, s_2, a_2, 0, s_3, a_3, -2)$			$(s_1, a_1, +5, s_2, a_2, 0, s_3, a_3, -2)$		
	A=3	A=3	A=3	A=3	A=2	A=2

$$\nabla \log f(x) = \frac{1}{f(x)} \cdot \nabla f(x)$$

Tip:

$$R(\tau^n) = \sum_{t=1}^{T_n} r_t^n, \text{ 在代码中是用的}$$

$$R(\tau^n) = \sum_{t'=t}^{T_n} \gamma^{t'-t} r_{t'}^n = G_t^n$$



Example:  $\tau^n = \{s_1^1, a_1^1, r_1^1, s_2^1, a_2^1, r_2^1, s_3^1, a_3^1, r_3^1, s_4^1, a_4^1, r_4^1, s_{t+1}^1\}$ ,  $\gamma=0.9$

当  $t=2$  时,  $R_0(\tau^n) = \sum_{t'=2}^4 0.9^{t'-2} r_{t'}^1 = 0.9^0 \cdot r_2^1 + 0.9^1 \cdot r_3^1 + 0.9^2 \cdot r_4^1$

$$\nabla \bar{R}_0 \approx \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T \left[ \frac{\sum_{t'=t}^T \gamma^{t'-t} r_{t'}^n}{G_t^n} - b \right] \nabla \log p(a_t^1 | s_t^1, \theta)$$

Q-Value Function 的定义:

由于  $G_t^n$  很不稳定, 是个随机变量, 于是考虑对其求期望。

$$q_{\pi}(s, a) = E_{\pi} [G_t | s_t, a_t]$$

$$E[G_t^n | s_t, a_t] = Q^{\pi_0}(s_t^1, a_t^1)$$

值函数  $V(s)$  从此刻到未来, 回报的期望

值函数  $Q(s, a)$  执行动作  $a$  后, 特回报的期望。

其中:  $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$

Q: Q 和 V 的关系?  $E(x) = \sum_i p(x_i) \cdot x_i$

$$q_{\pi}(s, a) = \sum_{r, s'} p(r, s' | s, a) [r + \gamma V_{\pi}(s')]$$

由女得到:  $b = V^{\pi_0}(s_t^1)$

$$= E[R_t + \gamma V_{\pi}(s_{t+1})]$$

又有两个网络。

$$\nabla \bar{R}_0 \approx \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T [Q^{\pi_0}(s_t^1, a_t^1) - V^{\pi_0}(s_t^1)] \nabla \log p(a_t^1 | s_t^1, \theta)$$

推知:  $Q^{\pi_0}(s_t^1, a_t^1) = E(r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1)) \approx r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1)$

这里的  $\approx$  虽然增大随机性,

但是  $r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1)$  是随机的

相比  $G_t^n$  会小很多。

于是:  $A^{\pi_0}(s_t, a_t) = R_0(\tau^n) - b \approx \frac{\sum_{t'=t}^T \gamma^{t'-t} r_{t'}^n}{G_t^n} - b$

Q:  $Q(s_t, a_t) = E(r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1))$

$$\approx E[G_t^n] - b = Q^{\pi_0}(s_t^1, a_t^1) - b = Q^{\pi_0}(s_t^1, a_t^1) - V^{\pi_0}(s_t^1)$$

还是  $E(r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1))$  ?  
↓  
gamma V

$$= E(r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1)) - V^{\pi_0}(s_t^1) \approx r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1) - V^{\pi_0}(s_t^1)$$


$V: NN$   
 $p: NN$

$$\nabla \bar{R}_0 \approx \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T [r_t^1 + \gamma V^{\pi_0}(s_{t+1}^1) - V^{\pi_0}(s_t^1)] \nabla \log p(a_t^1 | s_t^1, \theta)$$

④

Advantage

流程:



TIP:

和环境作互动的 policy/Action

就是要学习的 policy/Action


因此这里方法是 on-policy 的学习方法。

因此这个方法叫做: Advantage Actor-Critic : AAC

Actor: Policy-Based


Critic: Value-Based

AC 有两个网络:  $\begin{cases} \pi_{\theta}(s): NN_1 \\ V^{\pi_{\theta}}(s): NN_2 \end{cases}$ , 两个网络是可以共用参数的。



Q: 所谓共用参数, 应该不是所有的参数都共用吧?

$\pi_{\theta}(a|s)$  和  $V_{\theta}(s)$  中的两个  $\theta$  是完全一样的吗? 不一样, 最后一部分不一样。



$$L_{critic} \approx \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T (V_{\theta}(s_t) - [r + \gamma V_{\theta}(s_{t+1})])^2$$

$$\nabla J_{actor} \approx \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T \underbrace{[r_t^n + V^{\pi_{\theta}}(s_{t+1}^n) - V^{\pi_{\theta}}(s_t^n)]}_{\text{Advantage}} \nabla \log p(a_t | s_t^n, \theta)$$

Tip:  $V$  是通过 TD 的方法得到的

Q: off-policy 相比 on-policy 的优点是什么?

Q: 实际当中会将一个 entropy 添加到 loss 相中, 为什么?

Q: 输出是怎么处理的?

NN 的输出  $\rightarrow$   $\begin{matrix} \text{out}_1 \\ \text{out}_2 \\ \text{out}_3 \end{matrix}$

概率分布  $\rightarrow$  
$$\text{policy} = \frac{[e^{\text{out}_1}, e^{\text{out}_2}, e^{\text{out}_3}]}{\sum_{i=1}^3 e^{\text{out}_i}}$$

$a = \text{np.random.choice}([0, 1, 2], p = \text{policy})$

Q: 实际当中 A3C 是怎么处理的?  
多个 worker 是怎么协同工作的。

Q: 请再仔细描述一下整个 A3C 的流程?

Q: A3C 擅长处理什么?  
又有什么局限?

Q: 相比 PPO, A3C 哪些方面  
比较弱?